

```

# -*- coding: utf-8 -*-
""" Created on Tue Mar 11 18:45:01 2019
@author: JoaoR """

'''-----Imports -----'''
import pandas as pd
import numpy as np
import nltk

dataframe = pd.read_csv("C:/Endereço do Arquivo/Ghdb.csv",
delimiter=";", error_bad_lines=False, engine='python')
'Path [Database]

dataframe.isnull().sum()
'Exibindo a quantidade de valores nulos no dataframe'

dataframe.fillna(' ', inplace=True)
'Substituindo os valores nulos por "missing".'

stopwords = [' ', ':', ';', '"', '-', '=', '"', '!', '?', '"', '"', '"', '(',
)', '\'', '@', '~', '/', '|', '*', '*', '*', '[', ']', ', ', '[', ']', ', ',
', ], ', '[', ']', '—', '—', '...', '+', '/\\', '\\', '****', '.', '\\', '$',
'#', '%', "'", '-', '&', '\\', './', './', './', './', '||', '/*', '@']
'Stopwords do NLTK definidas para o experimento'

'''-- Algoritmo para contar a quantidade de atributos na base -----'''

linhas = np.size(dataframe,0)
colunas = np.size(dataframe,1)
X = dataframe
'''Verifica-se a quantidade de linhas e colunas da base, e em seguida
faz uma cópia da base para a variável X'''

maior = 0
'inicia-se a variável que receberá a quantidade máxima de parametros'

for n in range (linhas):
    'Iniciando em 0, a cada linha faça:'

    token = X.iloc[n]['Dork']
    'A variável Operador recebe a Dork inteira de cada linha'

    token = nltk.word_tokenize(token)
    'A variável Operador é dividida por Espaços'

    token = [c for c in token if not c in stopwords]
    'Remove todas as stopwords definidas na lista Stopwords'

    token = ''.join(token)
    'Unifica todos os Caracteres da Base'

    token = [c for c in token if not c in stopwords]
    'Remove todas as stopwords definidas na lista Stopwords'

```

```

token = ''.join(token)
'Unifica todos os Caracteres da Base'

Tamanho = int(len(token))
'A variável tamanho recebe a quantidade de parametros que a Dork possui'

if Tamanho > maior:
    'Se a variável tamanho for maior que o máximo atual'

    maior = Tamanho
    'Atribui um novo valor máximo'

    print(X.iloc[n]['Dork'])
    print(maior)
    'Sempre que o algoritmo encontrar um novo valor máximo, ele exibe'
    'no Console a Dork e sua quantidade de caracteres.'

print(maior)
'Exibe o resultado Final'
'Resultado = 84'

'''----- Execução do Algoritmo -----'''

c = -1
'''Ajusta a variável C para qual atributo será recebido o valor; escolheu-se
-1 para que o laço de repetição consiga receber os valores de posição [0]'''

for i in range(maior):
    'Iniciando em 0, para cada coluna faça:'

    for n in range (linhas):
        'Iniciando em 0, a cada linha faça:'

        if X.iloc[n,i] == 'Missing':
            'Se o valor da célula for igual a missing, faça:'

            Dork = X.iloc[n]['Dork']
            'A variável Dork recebe a dork da linha N'

            Dork = nltk.word_tokenize(Dork)
            'A dork é tokenizada = Dividida em Corpus'

            Dork = [c for c in Dork if not c in stopwords]
            'Remove todas as stopwords definidas na lista Stopwords'

            Dork = ''.join(Dork)
            'A String Dork recebe a lista tokenizada'
            'e a unifica em uma única variável'

            Dork = [c for c in Dork if not c in stopwords]
            'Remove todas as stopwords definidas na lista Stopwords'

            Dork = ''.join(Dork)
            'A String Dork recebe a lista tokenizada'

```

```

'e a unifica em uma única variável'

DorkL = ""
'Inicia-se uma nova variável com valor vazio.'

if len(Dork) > c:

    DorkL = str(ord(str(Dork[c])))
    'Faz a Concatenação do Valor Ascii'

    X.iloc[n,i] = int(DorkL)
    'Atribui o valor'

else:

    X.iloc[n,i] = 1
    'X.iloc[n,i] = 0'
    'Caso a Dork seja menor que o atributo informado,'
    'não faz nada e atribui um valor nulo para a célula'

c = c + 1
'A cada laço de repetição, aumenta o valor do contador'
'para ir ao próximo atributo'

'''-----Escrita da Variável no CSV-----'''

X.to_csv('DorkDb_Final.csv', encoding='utf-8', index=False)

'''UTF8 - Codificação UTF-8 binária do documento compatível com ASCII,
permite que seu documento não tenha problemas com palavras acentuadas
e outras particularidades de formatação.

index=False Retira o index ao exportar os dados'''

```